# Il livello trasporto nella rete Internet: TCP e UDP

Mario BALDI
staff.polito.it/mario.baldi

Silvano GAI
sgai@cisco.com

Jim KUROSE
www-aml.cs.umass.edu

Fulvio RISSO
fulvio.risso@polito.it




# Nota di Copyright






# I protocolli TCP e UDP

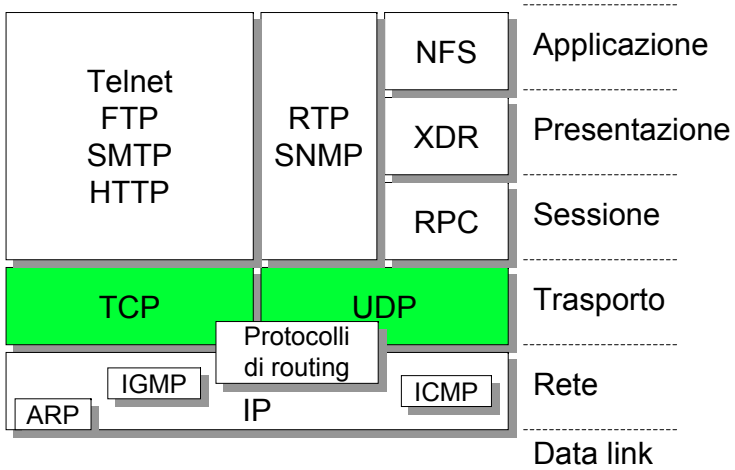





# Transport services and protocols

- provide *logical communication* between app' processes running on different hosts
- transport protocols run in end systems (primarily)

transport vs network layer services:

- *network layer:* data transfer between end systems
- *transport layer:* data transfer between processes
  - relies on, enhances, network layer services

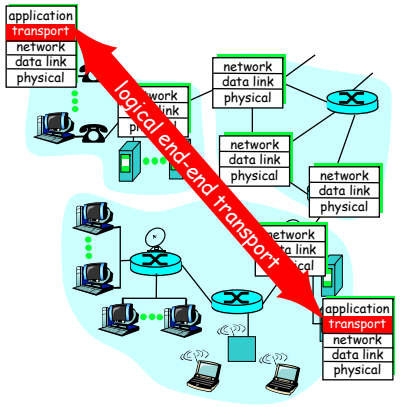

# TCP e UDP

- Due protocolli di trasporto alternativi
- Realizzano funzionalità comuni a tutti gli applicativi
- Possono operare simultaneamente con molti applicativi diversi, tramite il concetto di porta




# Transport-layer protocols

Internet transport services:

- reliable, in-order unicast delivery (TCP)
  - congestion
  - flow control
  - connection setup
- unreliable ("best-effort"), unordered unicast or multicast delivery: UDP
- services not available:
  - real-time
  - bandwidth guarantees
  - reliable multicast

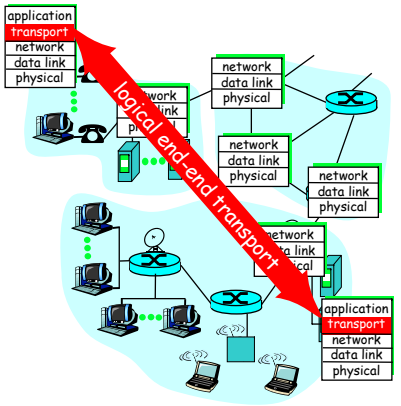





# Multiplexing/demultiplexing

Recall: *segment* - unit of data exchanged between transport layer entities

- aka TPDU: transport protocol data unit

Demultiplexing: delivering received segments (TPDUs)to correct app layer processes

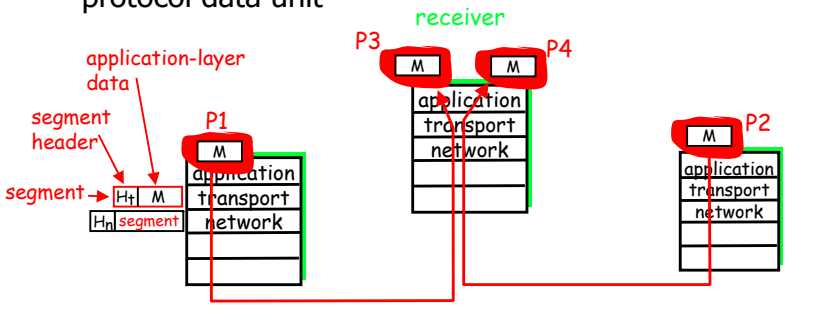





# Multiplexing/demultiplexing

Multiplexing: gathering data from multiple app processes, enveloping data with header (later used for demultiplexing)

multiplexing/demultiplexing:

- based on sender, receiver port numbers, IP addresses
  - source, dest port #s in each segment
  - recall: well-known port numbers for specific applications

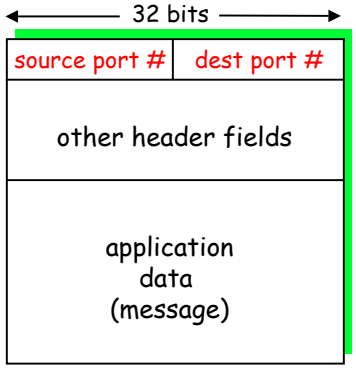


TCP/UDP segment format

## Multiplexing/demultiplexing: examples

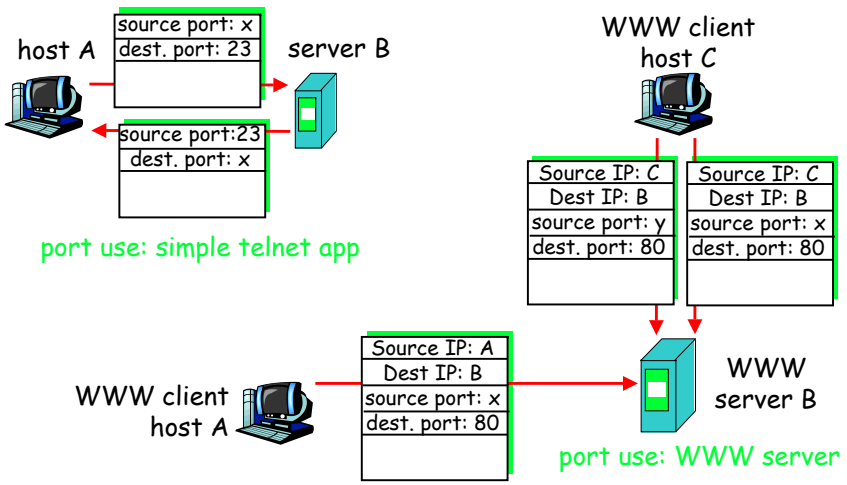





## Porte TCP e UDP

- Sono il mezzo con cui un programma client indirizza un programma server
- Numero naturale su 16 bit
- 0 ... 1023 = porte privilegiate
- 1024 ... 65535 = porte utente
- Porte statiche
  - quelle dove un server è in ascolto
- Porte dinamiche
  - quelle usate per completare una richiesta di connessione e svolgere un lavoro




## Well Known Port

- Sono associate agli applicativi principali, ad esempio:

| servizio | port | TCP | UDP |
|---|---|---|---|
| daytime | 13 | X | X |
| ftp | 21 | X | |
| telnet | 23 | X | |
| smtp | 25 | X | |
| tftp | 69 | | X |
| gopher | 70 | X | |
| finger | 79 | X | |
| http | 80 | X | |
| pop | 109 | X | |
| nntp | 119 | X | |

- Nonostante le porte UDP e TCP siano indipendenti si è scelto di non avere well known port sovrapposte
  - In questo modo è più semplice gestire servizi che possono essere chiamati sia via UDP che TCP




## UDP: User Datagram Protocol [RFC 768]

- Connectionless Transport Protocol
  - No handshaking between UDP sender, receiver
  - Each UDP segment handled independently of others
- "Best effort" service - UDP segments may be:
  - Lost
  - Delivered out of order to app

Same service as IP's?

Not exactly; it adds

- Multiplexing of various applications
  - Ports
- Checksum to verify data integrity
  - Optional

# UDP: User Datagram Protocol

- Non prevede controllo di flusso
  - Non è in grado di adattarsi autonomamente a variazioni di carico della rete
  - Non prevede meccanismi di ritrasmissione in caso di errori
  - Potrebbe congestionare la rete Internet




# Why UDP?

- No connection establishment
  - Which can add delay
- Simple
  - No connection state at sender, receiver
- Small segment header
  - Low transmission overhead
- No congestion control
  - UDP can blast away as fast as desired




# UDP: Formato dell'intestazione

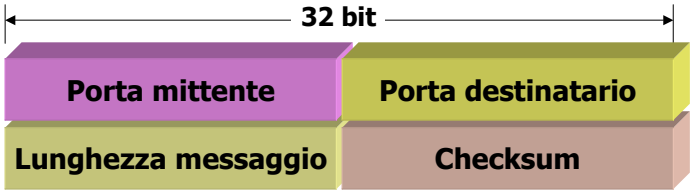


- Checksum e UPD Source sono opzionali: possono essere posti a 0
  - CRC= 0: non interessa il controllo errori sull'header
  - comunicazione monodirezionale




# UDP: applicabilità

- Si usa su rete affidabile oppure quando l'affidabilità non è importante
  - NFS (Network File System)
- L'applicazione mette tutti i dati in un singolo pacchetto
  - DNS
  - rwho
  - ruptime
- Non è importante che tutti i pacchetti arrivino a destinazione
  - Applicazioni multimediali
- Eventuali meccanismi di ritrasmissione (se necessari) vengano gestiti direttamente dall'applicazione
  - SNMP (Simple Network Management Protocol)

## UDP: applicazioni multimediali

- Caratteristiche
  - I dati devono arrivare entro un tempo limite
    - un pacchetto in ritardo equivale ad un pacchetto perso
  - l'applicazione non necessita di ritrasmissione
    - il ritardo introdotto sarebbe inaccettabile
  - è necessaria una "banda minima" per la comunicazione
- UDP è la scelta obligata
  - non ha controllo di flusso
- RTP (Real Time Transfer Protocol)
  - annullamento delle variazioni di ritardo
- H.323: standard per videoconferenza su IP
  - sincronizzazione tra i media
  - compatibilità con altre reti (ad esempio ISDN)




## UDP checksum

Goal: detect "errors" (e.g., flipped bits) in transmitted segment

Sender:

- treat segment contents as sequence of 16-bit integers
- checksum: addition (1's complement sum) of segment contents
- sender puts checksum value into UDP checksum field

Receiver:

- compute checksum of received segment
- check if computed checksum equals checksum field value:
  - NO - error detected
  - YES - no error detected. *But maybe errors nonethless?* More later ….




## TCP: Transmission Control Protocol

- Un protocollo di trasporto:
  - byte-oriented
  - connesso
- Utilizzato da applicativi che richiedono la trasmissione affidabile dell'informazione:
  - telnet
  - ftp (file transfer protocol)
  - smtp (simple mail transfer protocol)
  - http




## TCP: funzionalità

- Funzionalità TCP:
  - Supporto della connessione tramite circuiti virtuali
  - Error Checking
  - Controllo di flusso
  - Multiplazione e demultiplazione
  - Controllo di stato e di sincronizzazione
- TCP garantisce la consegna del pacchetto, UDP no!

## TCP: caratteristiche

- Come UDP ha il concetto di porta
- La comunicazione tra due entità TCP fa uso di un circuito virtuale
- Al circuito virtuale è associato un protocollo di trasporto
  - full-duplex
  - acknowledge
  - controllo di flusso
- TCP richiede più banda e più CPU di UDP
  - elaborazione più pesante
  - più informazioni di stato → maggiore memoria
  - più capacità tasmissiva
    - ritrasmissione
    - intestazione più grande




## TCP: caratteristiche

- TCP segmenta e riassembla i dati secondo le sue necessità:
  - non garantisce nessuna relazione tra il numero di read e quello di write
- Il TCP remoto deve fornire un acknowledge dei dati, normalmente tramite piggybacking
- Protocollo con sliding window, timeout e ritrasmissione




## TCP: Sliding Window

- I protocolli a sliding window richiedono di fissare la dimensione della finestra
- In TCP la dimensione della finestra è in byte, non in segmenti
- Il campo "window" del pacchetto TCP indica quanti byte possono ancora essere trasmessi prima di un ACK




## TCP: Timeout e Ritrasmissioni

- Per ogni pacchetto trasmesso viene inescato un timer
- Se un timer scatta senza aver ricevuto l'ACK relativo a quel pacchetto questo è ritrasmesso
- Ad ogni ritrasmissione di un pacchetto, sono ritrasmessi anche tutti gli altri pacchetti inclusi nella finestra
  - Può dare origine a congestioni
- Il timer è autoadattante
  - connessioni con basso Round Trip Delay hanno timer bassi
  - reagisce alle condizioni del traffico

# TCP: Formato dell'intestazione

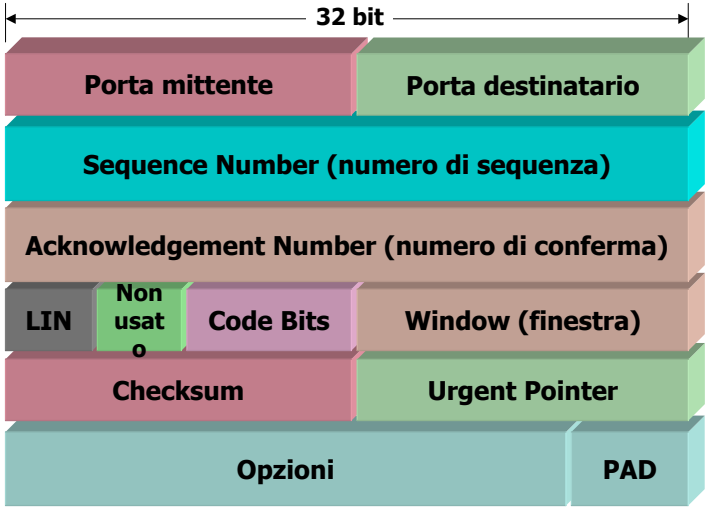





# TCP: Campi dell'intestazione (1)

- Source Port, Destination Port
- Sequence Number
  - Indica la posizione (in byte) di quel pacchetto all'interno del flusso
  - Il valore iniziale è scelto in maniera casuale all'inizio di ogni connessione ed indipendentemente da ogni macchina
- Acknowledge Number
  - Campo dedicato al piggyback degli acknowledgement
  - numero d'ordine del prossimo byte che il mittente del messaggio si aspetta di ricevere
- Header Lenght
  - Lunghezza dell'intestazione  in multipli di 32 bit




# TCP: Campi dell'intestazione (2)

- Reserved
  - Non usato
- Control
  - URG: Urgent Pointer is valid
  - ACK: Acknowledgement field is valid
  - PSH: This segment request a push
  - RST: Reset the connection
  - SYN: Synchronize sequence number
  - FIN: Sender has reached end of its byte stream




# TCP: Campi dell'intestazione (3)

- Window
  - Indica quanti byte il mittente del messaggio è in grado di ricevere a partire dall'ultimo byte confermato
  - L'host è in grado di ricevere quindi fino al numero di sequenza ACK + WINDOW
- Urgent Pointer
  - Indica che nel pacchetto ci sono uno o più byte urgenti
  - Lo stack TCP deve far in modo che l'applicazione interessata vada in "urgent mode". Solo dopo che i dati urgenti sono stati tutti consumati, l'applicazione può tornare in "normal mode"
  - Tipicamente associati ad eventi asincroni:
    - interrupt, abort, …
- Options
  - Maximum Segment Size (normalmente pari alla MTU)

# Connessioni

- TCP identifica un "canale" di comunicazione con il nome di connessione
- Sono identificate dalla quadrupla:

- <IP client><IP server><Port client><Port Server>
- | 32 bit | 32 bit | 16 bit | 16 bit |

- Questa soluzione permette
  - A client diversi di accedere allo stesso servizio sullo stesso server
  - Allo stesso client di attivare più sessioni dello stesso servizio
  - Viola il modello a livelli
    - informazioni di livello 3 usate a livello 4




# Connessioni multiple

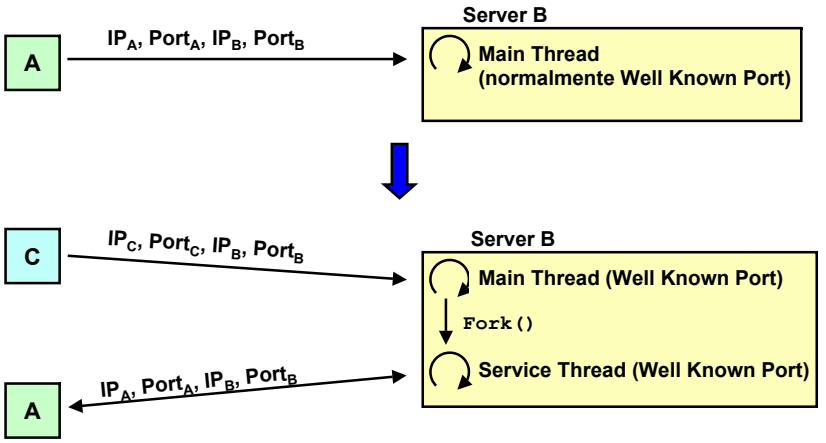





# Demultiplexing

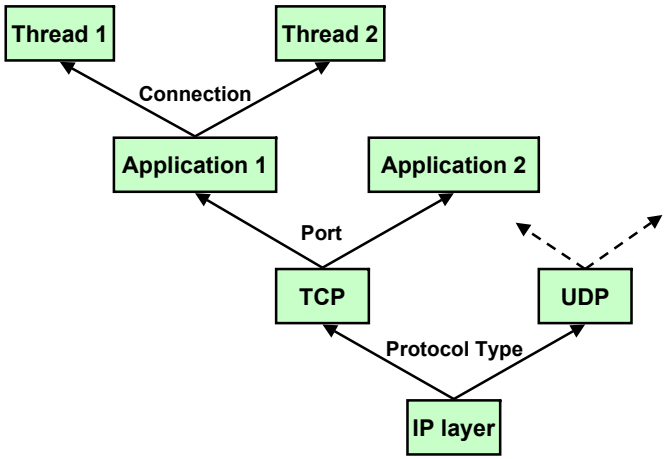





# Apertura della connessione

- Three way handshake

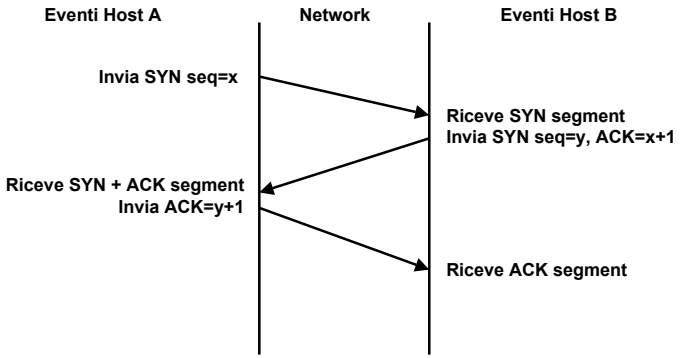

# Chiusura della connessione

- Three way handshake modificato

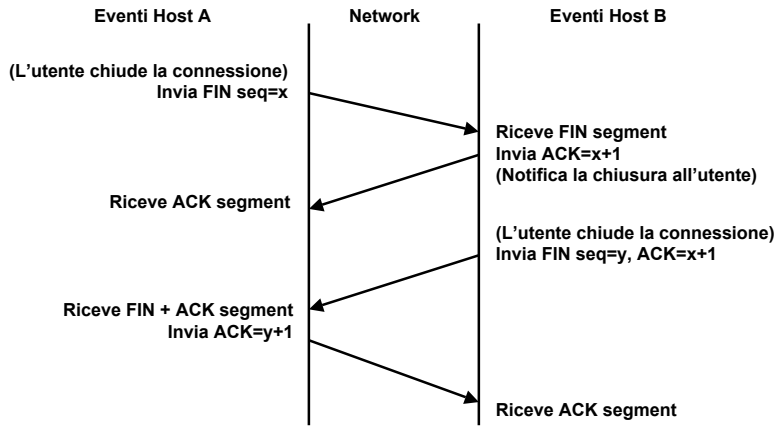





# Gestione della connessione: End-to-end flow control

- Controlla che il flusso di dati end to end sia accettabile
  - evita che il mittente trasmetta troppo velocemente se il destinatario non è in grado di riceverli
    - insufficiente potenza elaborativa o memoria
  - controlla che i pacchetti arrivino correttamente
    - si occupa della ritrasmissione dei pacchetti persi o erronei
    - elimina i pacchetti duplicati
- È basato su due meccanismi
  - Sliding window
    - regola la quantità di dati trasmessi la cui ricezione non è stata ancora confermata
  - Round Trip Estimate
    - stima il tempo necessario ad un pacchetto per raggiungere la destinazione e alla conferma per arrivare al mittente (round trip delay)
    - permette di determinare quando procedere alla ritrasmissione




# Gestione della connessione: Congestion Control

- La congestione è rilevata nel momento in cui un retransmission timer espira
- La versione base di TCP ritrasmette l'intera finestra di quando un timer espira
- Questo può causare gravi congestioni della rete (congestion collapse):
  - Nell'ottobre 1986 Arpanet fu bloccata da una congestione (da 32 kbs a 40 bps)
- Soluzioni
  - Multiplicative decrease window size
  - Slow start




# Sliding Window

- Controlla la quantità di dati che è possibile trasmettere prima di ricevere la conferma di ricezione
  - una finestra di N byte (N-window) consente la trasmissione di N byte prima che giunga l'acknowledge del primo trasmesso
- Vincola l'efficienza (throughput) sui lunghi percorsi
  - se la finestra non è più larga della memoria di canale, il trasmettitore si ferma

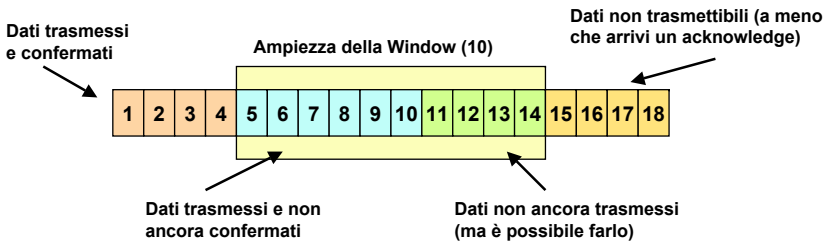

## Sliding Window

- In TCP la Window ha dimensione variabile
  - Deve essere stabilito un valore iniziale
    - può essere diverso per trasmettitore e ricevitore
    - viene negoziato all'apertura della connessione
  - All'apertura della connessione il ricevitore comunica al trasmettitore la dimensione della window ammessa
  - Durante lo scambio dati il ricevitore può diminuire la dimensione della window se il buffer di ricezione del TCP si sta riempiendo
    - il livello superiore non sta prelevando i dati dal livello TCP
    - si usa il campo window dei pacchetti trasmessi nella direzione opposta




## Sliding Window

- In TCP la dimensione della finestra è in byte, non in segmenti
  - Il campo window del pacchetto TCP indica quanti byte il mittente è in grado di ricevere a partire dall'ultimo byte confermato
- L'acknowledge è dato in forma "cumulativa"
  - L'arrivo di un ack relativo al byte X indica implicitamente che tutti i byte precedenti sono stati ricevuti
  - È un vantaggio se la connessione ha basso tasso di perdita
    - si diminuisce il traffico di controllo
  - Può essere svantaggioso nel caso di elevato tasso di perdite non consecutive
    - può essere ritrasmissa una sequenza di byte anche se questa era precedentemente arrivata correttamente




## Retransmission Timer

- Tempo massimo per cui si aspetta la conferma di avvenuta ricezione (acknowledgement)
- Alla trasmisssione di ogni segmento viene fatto partire un timer
  - se il timer espira prima di aver ricevuto la conferma di ricezione di quel segmento, avviene la ritrasmissione
- Un segmento è considerato confermato anche se lo è un segmento che lo segue nel flusso dati




## Retransmission Timer

- Il timer è autoadattante
  - la durata dipende dalle condizioni del traffico
    - connessioni con basso Round Trip Delay hanno timer brevi
  - si adatta ad eventuali variazioni del round trip time medio evitando ritrasmissioni
    - ad ogni ack ricevuto il valore del timer viene ricalcolato per tenere conto delle variazioni di round trip time
- Tutta la Window viene ritrasmessa
  - può dare origine a congestioni
  - intervengono i meccanismi di Congestion Control

## Congestion Control: Multiplicative decrease window size

- Nel momento in cui si verifica una congestione non è opportuno ritrasmettere l'intera window
  - questo può portare ad un peggioramento della congestione
- Si adotta un meccanismo di ritrasmissione di tipo esponenziale decrescente
  - la dimensione della window viene dimezzata
  - se il retransmission timeout espira nuovamente, la diminuzione della window viene iterata
  - si procede fino a quando la ritrasmissione permessa è di un solo segmento




## Congestion Control: Multiplicative decrease window size

- Si definiscono 2 nuove window
  - receiver_window: numero di segmenti di dimensione massima che il ricevitore è in grado di ricevere
  - congestion_window: esprime il numero di segmenti inviabili nel caso di congestione
- In ogni momento si ha:
  - Allowed_window = min (receiver_window, congestion_window)
- Se non ci sono congestioni la congestion window corrisponde alla receiver window
- In caso di congestione
  - congestion_window viene dimezzata (fino alla dimensione minima di 1 messaggio)
  - il retransmission_timer dei messaggi che sono inclusi nella finestra viene moltiplicato per un fattore N




## Congestion Control: Multiplicative decrease window size

- Backoff timer
  - il retransmission timer dei segmenti che si trovano nella window viene aumentato in modo esponenziale (raddoppiato) ogni volta che si ha un timeout
    - anche quando la window ha la dimensione di 1 segmento
  - si evitano troppe ritrasmissioni nel caso in cui le conferme siano semplicemente in ritardo




## Congestion Control: Slow Start

- Garantisce una crescita graduale del bit rate
- Entra in azione sia dopo una congestione sia all'apertura di una connessione
  - Nel caso si provenga da una congestione non è opportuno riportare il bit rate a quello precedente la congestione in quanto può dare origine a oscillazioni
- Congestion Window
  - Viene inizializzata ad 1 segmento
  - Viene incrementata all'arrivo di ogni conferma (crescita lineare)
    - Inizio: congestion = 1 → trasmette 1 segmento
    - Riceve 1 ack → congestion = 2 → può trasmettere fino a 2 segmenti
    - Riceve 2 ack → congestion = 4 → … fino a 4 segmenti
    - …

# Congestion Control: Slow Start

- Congestion avoidance
  - Raggiunta una dimensione pari alla metà della window in uso quando si è verificata la congestione, si entra in una fase di congestion avoidance
  - in questa fase la congestion window viene incrementata linearmente
    - 1 segmento per ogni finestra ricevuta correttamente
- Ad un certo punto inizia a prevalere la receiver_window
- Questo algoritmo è stato proposto da Nagle (1987)